

Assignment 5: Domain Adaptation with Language Model

Nandar Linn

Corpus Preparation & Data Preprocessing

- Language Model အတွက် Raw Data များတွင် ပါရှိသော မလိုအပ်သည့် Tags, Punctuation နှင့် Non-Burmese စာသားများကို ဖယ်ရှားခဲ့ပါတယ်။
- Test Set များအတွက် Token 300 စီ ဖြတ်တောက်ထားပါတယ်။

Corpus Resources

- ALT Tree Bank (<https://www2.nict.go.jp/astrec-att/member/mutiyama/ALT/>)
- myPOS (<https://github.com/ye-kyaw-thu/myPOS>)
- myanmar-literature -corpus (Huggingface)
- LLM Generated Corpus

Tokenization (Syllable Segmentation)

- Dr. Ye Kyaw Thu ၏ myWord အသုံးပြု၍ Syllable Tokenization ပြုလုပ်ထားပါတယ်။

Train Base LM

- Syllable ဖြတ်ထားသော General Domain Data ပေါ်တွင် KenLM ကို အသုံးပြု၍ 5-gram Base Language Model (.arpa နှင့် .binary formats) ကို တည်ဆောက်ထားပါတယ်။


Testset ပြင်ဆင်ခြင်း

Base LM နှင့် Token Type တူညီစေရန် Syllable ဖြတ်ထားသော အောက်ပါ Domain (၃) ခုအတွက်

Test Data များ ပြင်ဆင်ထားပါသည်-


- News Articles
- Literary/Novel Text
- Medical/Health Text

Compute PPL & Visualization



Literature text တွေမှာ PPL Score အများဆုံး တွေရတဲ့အတွက် vocabulary expansion လုပ်ပြီး ထပ်မံစမ်းသပ်ခဲ့ပါတယ်။

After Domain-specific Vocabulary Expansion



Vocabulary expansion လုပ်ပြီးတဲ့နောက်မှာ Literature text တွေရဲ့ PPL score က 36.98% ကို ကျဆင်းသွားတာ တွေ့ရပါတယ်။

Conclusion

- General domain corpus ဖြင့် တည်ဆောက်ထားသော language model သည် specific domain တွင် တိုက်ရိုက်အသုံးပြုရန် အခက်အခဲရှိကြောင်း သိရပါတယ်။
- သို့သော် domain adaptation strategy တစ်ခုဖြစ်သည့် vocabulary expansion နည်းလမ်းကို အသုံးပြုလိုက်သောအခါ model ၏စွမ်းဆောင်ရည်သည် သိသိသာသာ တိုးတက်လာတာ တွေ့ရပါတယ်။
- ထို့ကြောင့် language model တစ်ခုကို specific domain တွင် လက်တွေ့အသုံးပြုလိုပါက in-domain data များဖြင့် domain adaptation ပြုလုပ်ခြင်းသည် model ၏ accuracy နှင့် usability ကို မြှင့်တင်ပေးနိုင်တယ်လို့ ကောက်ချက်ချပါတယ်။

Thank You